

공유오피스 무료체험 결제전환 분석 보고서

체험자의 어떤 이용 패턴이 결제전환으로 이어지는가?

2026년 6월

1. 분석 개요

1.1 분석 배경 및 목적

공유오피스 운영사는 신규 고객 유치를 위해 3일 무료체험 프로그램을 운영하고 있다. 체험 후 유료 멤버십으로 전환하는 비율을 높이는 것이 핵심 비즈니스 과제로, 본 분석은 체험자의 이용 행동 데이터로부터 결제전환에 실질적인 영향을 미치는 패턴을 파악하고, XGBoost 모델을 통해 통계적으로 검증하는 것을 목적으로 한다.

1.2 데이터 개요

분석에 활용된 데이터는 총 5개 테이블이며, 수집 기간은 2021년 5월부터 2023년 12월이다.

테이블	주요 컬럼	원본 행수	정제 후 행수
trial_register	user_uuid, trial_date	9,659	9,624
trial_access_log	user_uuid, checkin(1=입실/2=퇴실), cdate	63,708	63,349
trial_visit_info	user_uuid, date, stay_time_second, first_enter_time, last_leave_time	11,477	10,874
trial_payment	user_uuid, is_payment	9,659	9,624
site_area	site_id, area_pyeong	9	9

1.3 전처리 내용

각 테이블에서 발견된 데이터 품질 이슈를 아래와 같이 처리하였다.

테이블	이슈 유형	처리 방법
register	동일 (user_uuid + trial_date) 중복 28건+ 동일 user_uuid 재신청 35건	마지막 신청 기준 1인 1체험신청으로 통합
access_log	완전 중복 행 359건	마지막 건 유지

visit_info	입퇴실 시각 동시 결측 555건 / 중복 48건	결측 행 제거, 중복 최종 건 유지
payment	완전 중복 행 35건	마지막 건 유지
access_log	UTC 기준 시각	KST(+9h) 변환 후 사용

1.4 분석 대상 범위

전체 신청자 9,624명 중 체험기간 내 실제 방문 기록이 있는 5,629명을 분석 대상으로 한정하였다.

미방문자(3,492명)는 '이용 패턴 → 결제전환'이라는 인과구조가 적용되지 않아 제외하였으며, 방문일수가 4일 이상인 비정상 레코드 75건도 제외하였다.

구분	인원	비율	비고
전체 신청자	9,624명	100%	
미방문자 (분석 제외)	3,492명	36.3%	이 중 37.6%가 결제 — 별도 경로(가상오피스 등) 추정
방문자 (1차 분석 대상)	6,132명	63.7%	체험기간 내 1회 이상 방문
최종 머신러닝 표본	5,629명	-	- 기준 : 무료체험 방문 일자 $0 < n < 4$ - 무료체험 방문 일자 0일을 제외(492명), - 파생변수 생성 과정에서 발생한 결측치 제외(11개)

▶ 중요 전처리 사유:

무료체험 신청일과 첫 방문일이 동일한 사용자(**first_visit_delay=0**)는 신청과 방문의 시간적 선후관계가 명확하지 않았다. 기존 이용자가 당일 무료체험을 등록한 경우와 무료체험 신청 직후 방문한 경우를 구분할 수 없었기 때문에, 무료체험 이후의 행동을 분석하기 위해 해당 사용자는 분석 대상에서 제외하였다.

2. 탐색적 데이터 분석(EDA)

본 분석에서 도출된 주요 인사이트를 정리하면 다음과 같다.

번호	발견 내용	시사점
1	방문일수가 많을수록 결제전환율이 높다 (33% → 46%)	체험 기간을 성실히 활용한 사람이 결제로 이어짐
2	체류시간이 길수록 결제율이 오히려 낮아진다 (역U자)	'빠른 판단'이 '오랜 고민'보다 결제전환에 유리
3	첫 방문이 늦을수록 결제율이 높다 (32% → 44%)	미리 계획하고 방문한 '진성 수요'의 전환율이 높음
4	코로나 기간 결제율이 엔데믹 이후보다 7%p 높다	수요 특성이 시기에 따라 구조적으로 다름
5	방문일수 多 + 체류시간 短 조합이 최고 전환율(57.5%)	여러 날 효율적으로 체험한 패턴이 결제에 가장 유리
6	하루 입실횟수가 많을수록 전환율이 낮다	잡은 출입보다 집중적 이용이 결제를 유도

2.1 가설 1 — 방문일수가 많을수록 결제 가능성이 높다

체험기간 3일 중 며칠을 방문했는지에 따라 결제율에 명확한 단조증가 패턴이 나타났다.

방문일수	인원	결제율
1일	3,049명	33%
2일	1,836명	41%
3일	1,247명	46%

▶ 가설 채택. 방문일수와 결제율 간 양(+)의 상관관계가 명확히 존재한다. 3일을 꼭 채워 체험한 사람의 결제율(46%)은 1일만 온 사람(33%)보다 13%p 높다.

연속방문일	방문인원	결제인원	결제율
0일	492명	216명	43.9%
1일	3357명	1181명	35.2%

2일	1995명	843명	42.3%
3일	288명	99명	34.4%

2.2 가설 2 — 체류시간이 길수록 결제 가능성이 높다.

1일 평균 체류시간(avg_stay_hour)을 1시간 단위로 구간화하여 결제율을 확인한 결과, 예상과 다른 역U자 패턴이 나타났다.

일 평균 체류시간	인원	결제율
1시간 미만	642명	41.6%
1~2시간	703명	44.4%
2~3시간	812명	46.2%
3~4시간	913명	40.9%
4~5시간	832명	38.3%
5~6시간	673명	33.1%
6시간 이상	1,557명	30.2%

▶ 가설 기각 (반대 방향). 2~3시간대에서 결제율이 최고점(46.2%)을 기록하고, 이후 체류시간이 늘어날수록 결제율이 하락한다.

2.3 가설 3 — 신청 후 첫 방문이 빠를수록 결제 가능성이 높다.

신청일 기준 첫 방문까지 걸린 지연일(first_visit_delay)별 결제율을 분석한 결과, 예상과 완전히 반대되는 단조증가 패턴이 나타났다.

첫 방문 지연일	인원	결제율
당일(0일)	1,410명	32.3%
1일 후	3,257명	39.0%
2일 후	971명	40.8%

3일 후	494명	44.1%
------	------	-------

▶ 가설 기각 (반대 방향). 신청 당일 즉시 방문한 그룹(32.3%)이 가장 낮고, 오히려 3일 후에 처음 방문한 그룹(44.1%)이 결제율이 가장 높다. 이는 '계획적으로 방문 시점을 잡은 진성 수요'가 전환율이 높다는 해석과 맞닿는다.

2.4 가설 4 — 지점 면적이 클수록 결제 가능성이 높다.

지점 면적(area_pyeong) 구간별 결제율 차이를 분석하였다.

면적 구간	결제율
50평	39%
100평	35%
150평	39%

▶ 가설 기각. 면적 규모에 따른 결제율 차이가 거의 없다.. 이후 다중공선성 체크 및 모델 유의성 검증에서도 area_pyeong은 유의미하지 않았다.

2.5 가설 5 — 엔데믹 이후 전환율이 낮아질 것이다

시기	인원	결제 수	결제율
코로나 기간 (2021.06 ~ 2023.05.05)	4,537명	1,813명	39.96%
엔데믹 이후 (2023.05.06 ~ 2023.12)	1,595명	526명	32.98%

▶ 가설 채택. 코로나 기간(39.96%)과 엔데믹 이후(32.98%) 간 약 7%p 차이가 확인됐으며, 카이제곱 검정 결과 통계적으로 유의하다($p < 0.001$). 코로나 기간 중 재택근무 수요 증가로 진성 수요층이 두텁게 형성된 것으로 해석된다.

2.6 하루 평균 입실횟수와 결제율

출입로그(trial_access_log)에서 도출한 하루 평균 입실횟수(avg_daily_enter)와 결제율의 관계를 분석하였다.

입실 횟수 구간	인원	결제율
1회	1,095명	42.2%
2~3회	2,005명	36.8%
4~5회	1,322명	36.8%
6~10회	934명	34.7%
10회 이상	85명	30.6%

▶ 입실횟수가 적을수록 결제율이 높은 패턴을 보임. 하루 평균 입퇴실 횟수가 많은 사람보다 적은 사람이 더 높은 전환율을 보인다. 이는 avg_stay_hour의 역U자 패턴과 비슷하다.

2.7 방문일수 × 체류시간 교차 분석

방문일수와 총 체류시간을 각각 중앙값 기준으로 나누고 4개 그룹으로 교차 분석하였다.

그룹	인원	결제율	해석
방문일수 많음 + 체류시간 짧음	642명	57.5%	최고 전환율 — 여러 날 왔지만 효율적으로 체험
방문일수 많음 + 체류시간 김	2,441명	39.6%	보통
방문일수 적음 + 체류시간 짧음	2,424명	34.2%	보통
방문일수 적음 + 체류시간 김	625명	27.8%	최저 전환율 — 적게 왔지만 오래 머물

▶ '방문일수 많음 + 체류시간 짧음' 조합이 57.5%로 가장 높은 전환율을 기록했다.

무료체험기간을 다 채우면서도 체류시간은 짧게 이용한 패턴이 결제전환이 가장 높게 나타났다.

3. 머신러닝 모델링

분류 모델 선택 근거

본 분석의 종속변수인 **is_payment**는 결제 여부를 나타내는 이진값(0=미결제, 1=결제)으로, 연속값을 예측하는 회귀(Regression)가 아닌 **이진 분류(Binary Classification)** 문제로 정의했다.

EDA를 통해 개별 변수와 결제율 간의 단변량 관계를 확인하였으나, 여러 이용 패턴 변수가 동시에 작용하는 다변량 구조에서의 순수한 효과를 분리하고 통계적으로 검증하기 위해 머신러닝 모델을 추가로 적용하였다. 이를 통해 EDA에서 발견한 패턴(방문일수, 체류시간, 첫방문 지연일 등)이 다른 변수를 통제된 상태에서도 유의미한 신호인지 확인하고, 체험자 개인 단위의 결제전환 가능성을 수치화하는 것을 목적으로 한다.

3.1 Feature Engineering 및 변수 선택

분석 사용 변수 목록 및 피처 구분 (총 42개)

[실험별 피처 구성] 실험1: 기본 6개 | 실험2: 기본 6 + 추가 3 = 9개 | 실험3·4·7 & 최종 모델: 기본 6 + 추가 3 + 시기 1 = 10개 | 실험5·6: 9개(is_post_covid는 가중치 사용) | 실험8: 10개 + FE 32개 = 42개

피처 구분	변수명	설명	사용 실험
▶ 기본 피처 — 6개 (실험 1부터 전체 실험에 공통 사용)			
기본 피처	visit_days	체험기간 내 방문 일수 (1~3일)	실험 1 ~ 10
기본 피처	avg_stay_hour	1회 방문당 평균 체류시간 (시간)	실험 1 ~ 10
기본 피처	avg_daily_enter	하루 평균 입실 횟수	실험 1 ~ 10
기본 피처	first_visit_delay	신청일 ~ 첫 방문일 간 일수 차이	실험 1 ~ 10
기본 피처	consecutive_group_2일	연속 2일 방문 여부 (원핫인코딩, 0/1)	실험 1 ~ 10
기본 피처	consecutive_group_3일	연속 3일 방문 여부 (원핫인코딩, 0/1)	실험 1 ~ 10
▶ 추가 피처 — 3개 (실험 2부터 추가)			

추가 피쳐	first_visit_hour	첫 방문 시각 (0~23시)	실험 2 ~ 10
추가 피쳐	n_sites_visited	방문한 지정 수	실험 2 ~ 10
추가 피쳐	area_pyeong	방문 지정 면적 (평)	실험 2 ~ 10
▶ 시기 피쳐 — 1개 (실험 3부터 추가 → 최종 모델 완성)			
시기 피쳐	is_post_covid	엔데믹 이후 체험 여부 (0/1)	실험 3 · 4 · 7 · 8 · 9 · 10 ※ 실험 5·6은 피쳐 제외, sample_weight로만 사용
▶ Feature Engineering — 행동 강도 / 집중도 (5개)			
FE — 행동강도	stay_x_visit	평균 체류시간 × 방문일수	실험 8 - 10
FE — 행동강도	enter_x_visit	평균 입실향수 × 방문일수	
FE — 행동강도	stay_x_enter	평균 체류시간 × 평균 입실향수	
FE — 행동강도	enter_per_visit_day	방문일당 평균 입실향수	
FE — 행동강도	stay_per_enter	입실 1회당 평균 체류시간	
▶ Feature Engineering — 지연 관련 (4개)			
FE — 지연 관련	delay_per_visit_day	방문일 대비 첫 방문 지연일	실험 8 - 10
FE — 지연 관련	visit_delay_interaction	방문일수 × 첫 방문 지연일 (상호작용)	
FE — 지연 관련	is_fast_visit	첫 방문이 빠른 사용자 (delay ≤ 1, 0/1)	
FE — 지연 관련	is_delayed_visit	첫 방문이 늦은 사용자 (delay ≥ 3, 0/1)	

▶ Feature Engineering — 행동 유형 플래그 (4개)			
FE — 행동유형	is_frequent_user	방문 빈도 높은 사용자 (avg_daily_enter ≥ 2, 0/1)	실험 8 - 10
FE — 행동유형	is_long_stay	장시간 체류 사용자 (avg_stay_hour ≥ 2, 0/1)	
FE — 행동유형	is_short_frequent	짧게 자주 방문 (체류 < 1h & 입실 ≥ 2, 0/1)	
FE — 행동유형	is_long_frequent	오래 자주 방문 (체류 ≥ 2h & 입실 ≥ 2, 0/1)	
▶ Feature Engineering — 시간대 (4개)			
FE — 시간대	is_afternoon	오후 방문 여부 (12~18시, 0/1)	실험 8 - 10 ※ is_morning 피쳐는 포함하지 않음 (One-Hot Encoding)
FE — 시간대	is_evening	저녁 방문 여부 (18~22시, 0/1)	
FE — 시간대	first_visit_hour_sin	첫 방문 시각 sin 변환 (주기성 반영)	
FE — 시간대	first_visit_hour_cos	첫 방문 시각 cos 변환 (주기성 반영)	
▶ Feature Engineering — 시기 / 계절 (5개)			
FE — 시기/계절	trial_month	체험 신청 월 (1~12)	실험 8 - 10
FE — 시기/계절	trial_dayofweek	체험 신청 요일 (0=월 ~ 6=일)	
FE — 시기/계절	is_weekend_trial	주말 신청 여부 (0/1)	
FE — 시기/계절	trial_month_sin	신청 월 sin 변환 (계절 주기성 반영)	
FE — 시기/계절	trial_month_cos	신청 월 cos 변환 (계절 주기성 반영)	
▶ Feature Engineering — 상호작용 변수 (3개)			
FE — 상호작용	post_covid_x_visit_days	엔데믹 이후 × 방문일수	

FE — 상호작용	post_covid_x_avg_stay	엔데믹 이후 × 평균 체류시간	실험 8 - 10
FE — 상호작용	post_covid_x_daily_enter	엔데믹 이후 × 평균 입실횟수	
▶ Feature Engineering — 로그 변환 (6개)			
FE — 로그변환	log1p_avg_stay_hour	평균 체류시간 $\log(1+x)$ 변환 (우편향 보정)	실험 8 - 10
FE — 로그변환	log1p_avg_daily_enter	평균 입실횟수 $\log(1+x)$ 변환	
FE — 로그변환	log1p_first_visit_delay	첫 방문 지연일 $\log(1+x)$ 변환	
FE — 로그변환	log1p_area_pyeong	지점 면적 $\log(1+x)$ 변환	
FE — 로그변환	log1p_n_sites_visited	방문 지점 수 $\log(1+x)$ 변환	
FE — 로그변환	log1p_stay_x_visit	체류시간×방문일수 조합 $\log(1+x)$ 변환	

3.2 모델 실험 비교

여러 모델과 피쳐셋 조합을 실험하여 성능을 비교하였다.

▶ 최종 모델: XGBoost

선정 이유로는 다양한 모델 비교 결과 가장 안정적인 성능을 보였다. Feature Engineering 적용 시 성능 향상 폭이 가장 컸으며 비선형 관계와 변수 간 상호작용을 효과적으로 학습 가능 Threshold 및 Hyperparameter Tuning을 통해 최종 성능을 최적화하였다.

XGBoost	Accuracy	Precision	Recall	F1-score
실험1	0.59	0.44	0.31	0.37
실험3	0.60	0.48	0.55	0.51
실험4	0.63	0.44	0.56	0.49
실험7	0.58	0.48	0.52	0.50
실험8	0.54	0.44	0.77	0.56
실험9	0.52	0.43	0.84	0.57
실험10	0.44	0.40	0.94	0.56

모델 실험 결과 요약

※ 초록 행 = 해당 실험에서 Best 성능 모델 / 설정

실험 1

기본 6개 변수 | LR · RF · XGBoost 비교 (class_weight 미적용)

▶ 실험 목적

세 가지 분류 모델(Logistic Regression, Random Forest, XGBoost)의 기본 성능을 비교하는 베이스라인 실험이다.

클래스 불균형 보정 없이 기본 설정으로 학습하여, 이후 실험들의 비교 기준점(baseline)을 확보한다.

모델	Accuracy	Precision	Recall	F1-score
Logistic Regression	0.64	0.56	0.25	0.35
Random Forest	0.56	0.41	0.40	0.40

XGBoost	0.59	0.44	0.31	0.36
---------	------	------	------	------

→ LR이 Accuracy는 가장 높지만 Recall(0.25)이 매우 낮아 결제자를 거의 잡지 못함. class_weight 미적용이 원인.

▶ 분석 결과

Accuracy는 Logistic Regression이 가장 높았지만 Recall이 0.25로 매우 낮아 실제 결제 고객을 충분히 찾아내지 못했다. 따라서 Accuracy보다 Recall을 개선하는 방향으로 이후 실험을 진행하였다.

실험 3

is_post_covid 추가 (10개 변수)

▶ 실험 목적

실험 1에서 확인된 두 가지 문제를 동시에 개선한다.

- ① class_weight='balanced' 적용 → 클래스 불균형 보정
- ② is_post_covid 변수 추가 → 코로나 기간(전환율 40%)과 엔데믹 이후(33%)의 구조적 차이를 모델에 반영

모델	Accuracy	Precision	Recall	F1-score
Logistic Regression	0.59	0.46	0.55	0.50
Random Forest	0.61	0.48	0.35	0.41
XGBoost	0.60	0.48	0.55	0.51

→ class_weight 적용 후 Recall 대폭 개선. XGBoost F1(0.51)이 가장 균형적.

▶ 분석 결과

class_weight를 적용한 결과 Recall이 크게 향상되었으며, XGBoost가 Precision과 Recall의 균형이 가장 우수하여 이후 실험의 기준 모델로 선정하였다.

실험 4

엔데믹 이후 6개월 데이터만 사용 (is_post_covid=1, n=1,488)

▶ 실험 목적

실험 3에서 `is_post_covid`가 유의미한 변수임을 확인했다. 엔데믹 이후 기간만 떼어내어, 이 시기에 한정된 이용 패턴이 결제전환을 예측하는 데 얼마나 효과적인지 별도로 검증한다.

또한 전체 데이터(실험 3) 대비 서브셋으로 학습했을 때 성능이 어떻게 달라지는지 비교한다.

모델	Accuracy	Precision	Recall	F1-score
Logistic Regression	0.62	0.44	0.65	0.53
Random Forest	0.67	0.48	0.31	0.37
XGBoost	0.63	0.44	0.56	0.49

→ LR이 Recall(0.65) 및 F1(0.53) 기준 최고. 데이터가 줄어 RF·XGB는 오히려 성능 하락.

▶ 분석 결과

엔데믹 이후 데이터만 학습했을 때는 Logistic Regression의 성능이 가장 높았지만, 데이터 수가 감소하면서 Random Forest와 XGBoost의 일반화 성능은 다소 감소하였다.

실험 7

코로나 기간 데이터만 사용 (`is_post_covid=0`, $n=4,141$) — 실험 4의 반대

▶ 실험 목적

실험 4(엔데믹 이후)의 반대 케이스로, 코로나 기간 데이터만 사용해 동일한 모델을 학습한다.

두 실험(4 vs 7) 결과를 비교해 시기별로 '이용 패턴 → 결제전환' 인과구조에 차이가 있는지 검증한다.

만약 성능이 유사하다면, 데이터를 시기별로 분리하는 것보다 전체 데이터에 `is_post_covid`를 feature로 포함하는 것이 더 효율적인 전략이다.

모델	Accuracy	Precision	Recall	F1-score
Logistic Regression	0.60	0.50	0.53	0.52
Random Forest	0.57	0.44	0.31	0.37
XGBoost	0.58	0.48	0.52	0.50

→ 코로나 기간 데이터만으로도 LR F1(0.52)이 가장 높음. 엔데믹 이후(실험4)와 성능 유사.

▶ 분석 결과

코로나 기간 데이터만 사용한 경우에도 Logistic Regression이 가장 안정적인 성능을 보였으며, 시기에 따른 모델 성능 차이는 크지 않은 것으로 확인되었다.

실험 8

Feature Engineering 적용 — 기존 10개 vs FE 포함 42개 × Threshold 비교

▶ 실험 목적

기존 원시 변수(10개)에 Feature Engineering으로 생성한 조합 변수 32개를 추가해 총 42개 변수로 성능이 향상되는지 확인한다.

또한 분류 Threshold를 기본값(0.5)에서 낮춰(0.4) Precision과 Recall 간 트레이드오프를 조정한다.

FE 변수 유형: 행동강도(stay × visit 등), 자연 관련, 행동유형 플래그, 시간대, 계절 주기성(sin/cos), 상호작용, 로그 변환 등

피처세트	피처수	Threshold	Accuracy	Precision	Recall	F1-score
XGBoost_FE_피처	42	0.5	0.62	0.49	0.55	0.52
기존 피처	10	0.5	0.61	0.48	0.55	0.52
XGBoost_FE_피처	42	0.4	0.54	0.44	0.77	0.56
기존 피처	10	0.4	0.53	0.43	0.76	0.55

→ Threshold 0.4 적용 시 Recall·F1 대폭 개선. FE 추가 효과는 미미($F1 + 0.01$ 수준). ROC-AUC는 두 피처세트 모두 0.63으로 동일.

▶ 분석 결과

Feature Engineering을 적용한 결과 ROC-AUC는 동일했지만 Threshold를 0.4로 조정하면서 Recall과 F1-score가 향상되었다. 즉, 성능 개선에는 Feature 추가보다 Threshold 조정의 영향이 더 크게 작용하였다.

실험 9

최적 Threshold 탐색 — F1-score 기준 (XGBoost_FE_피처 기반)

▶ 실험 목적

실험 8에서 Threshold 조정이 성능에 큰 영향을 미침을 확인했다. 이번 실험에서는 0.30~0.70 범위를 0.01 단위로 탐색해 F1-score를 최대화하는 최적 Threshold를 찾는다.

Threshold	Accuracy	Precision	Recall	F1-score
0.36 ★ (Best)	0.52	0.43	0.84	0.57

→ F1 최대점은 Threshold=0.36, F1=0.57. Recall 0.84로 결제자의 84%를 포착하지만 Precision은 0.43으로 낮음.

실험 10

XGBoost 하이퍼파라미터 튜닝 — 최종 선택 모델

▶ 실험 목적

실험 8~9에서 도출한 최적 피쳐셋(42개)과 Threshold(0.35~0.36)를 기반으로, XGBoost의 하이퍼파라미터(n_estimators, max_depth, learning_rate, subsample, colsample_bytree 등)를 RandomizedSearchCV로 튜닝해 최종 모델의 성능을 최대화한다.

모델	Threshold	Accuracy	Precision	Recall	F1-score	ROC-AUC
튜닝 XGBoost (최종)	0.35	0.44	0.40	0.94	0.56	0.63

→ 튜닝 후 Threshold=0.35에서 Recall 0.94 달성. 결제 가능성 있는 사람을 94% 포착. ROC-AUC=0.63으로 안정적 판별력 유지.

▶ 분석 결과

Hyperparameter Tuning을 적용한 최종 XGBoost 모델은 Recall 0.94를 달성하여 결제 가능성이 높은 고객을 가장 효과적으로 탐지하였다. 운영 목적상 결제 고객을 최대한 놓치지 않는 것이 중요하므로 최종 모델로 선정하였다.

3.3 분류 성능 평가

지표	Class 0 (미결제)	Class 1 (결제)	전체
Precision	0.69	0.45	-
Recall	0.57	0.58	-
F1-score	0.62	0.51	0.57 (acc)
AUC-ROC	-	-	0.615

AUC-ROC 0.615는 랜덤(0.5) 대비 통계적으로 유의미하게 높은 수준이다. 본 모델의 핵심 목적이 '정밀한 결제 예측'보다 '이용 패턴 → 결제전환 간 인과 관계 규명'임을 감안하면 적합한 성능이다. 4개 변수 모두 $p < 0.001$ 로 유의하며, 변수 축소 전후 AUC 차이가 0.0003에 불과해 핵심 신호를 안정적으로 포착하고 있다.

3.4 오탐(FP) 분석

최적 Threshold(0.35) 적용 시 F1-score 기준 0.57을 달성하였다. 실제 미결제자임에도 결제로 예측된 600명(False Positive)을 K-Means(k=4) 클러스터링으로 세분화하면 다음과 같다.

클러스터	인원	비율	주요 특성
Cluster 0 — 평균형	118명	19.7%	예측확률 0.55, 체류시간 4시간, 입실 3.4회
Cluster 1 — 단기체류형	91명	15.2%	예측확률 0.55, 체류시간 1.2시간 (최단), 입실 1.6회
Cluster 2 — 고활동형	157명	26.2%	예측확률 0.55, 체류시간 6.6시간, 입실 5.6회, 방문 2.7일
Cluster 3 — 다수/경계형	234명	39.0%	예측확률 0.51 (최저), 경계선에 걸린 불확실한 그룹

FP 분석을 통해 '결제할 것처럼 행동하지만 실제로는 결제하지 않는 그룹'의 특성을 파악하였다.

특히 Cluster 2(고활동형 FP)는 방문 빈도와 체류시간이 모두 높지만 결제로 이어지지 않는 패턴.

4. 분석 한계

본 분석 결과를 해석할 때 다음 한계점을 고려해야 한다.

- 결제 시점 정보 부재: **trial_payment**에 결제 일시 컬럼이 없어 체험기간 중 결제 여부를 알 수 없다. 결제 전 행동을 **feature**로 구분하지 못한 구조적 제약이 있다.
- 체험기간 정의 불확실: **trial_date**를 체험 시작일로 가정하였으나, 실제 운영 정책상 시작일이 다를 수 있다. 이 경우 **first_visit_delay** 계산이 달라질 수 있다.
- 방문일수 경계 케이스: **visit_days = 4** 이상인 75건(타임존 경계 추정)을 제외하였으나 정확한 원인이 확인되지 않았다.
- 모델 설명력 제한: **Pseudo R² = 0.033**으로 낮으며, 사람의 결제 결정에는 가격, 경쟁사 비교, 개인 사정 등 데이터에 없는 요인이 많이 작용한다.

5. 향후 제안

5.1 모델 활용 방안

① 결제전환 가능성 점수(Score) 운영

로지스틱 회귀 모델의 예측 확률값(0~1)을 '전환 가능성 점수'로 활용할 수 있다. 체험 2~3일차 시점에서 실시간 점수를 계산하여, 점수가 낮은 그룹(예: 0.35 미만)에게 우선적으로 영업팀이 개입하거나 인센티브를 제공하는 방식이다.

- 예) 체험 2일차 점수 0.3 이하 → 자동 문자 발송: '남은 1일, 궁금한 점을 직접 도와드릴게요!'
- 예) 점수 0.5 이상 → 결제 전환 촉진 프로모션 우선 발송 (첫 달 20% 할인 등)

② 방문 패턴별 세그먼트 마케팅

EDA에서 '방문일수 多 + 체류시간 短' 조합(57.5%)과 '방문일수 少 + 체류시간 長' 조합(27.8%) 간 결제율 차이가 약 30%p 달했다. 세그먼트별 차별화된 전략이 효과적이다.

- 고활동·단기체류형(FP Cluster 2): 자주 오지만 결제를 안 하는 그룹 — '어떤 점이 불만족스러웠나요?' 퇴장 후 피드백 설문 → 진짜 이유 파악
- 단기방문형(방문일 1일, 당일): '하루 만에 모든 시설을 충분히 보기 어렵습니다. 특화 투어를 신청해보세요' 식의 추가 체험 유도

5.2 데이터 수집 개선 제안

- 결제 시점 타임스탬프 기록: is_payment(0/1) 외에 결제 일시를 함께 기록하면, 체험기간 내/외 결제 여부를 분리하여 데이터 누수 없는 더 정확한 모델 구축이 가능하다.
- 체험 종료 후 설문 데이터 연결: '결제하지 않은 이유', '다른 공간 대안', '가격 민감도' 등 정성 데이터와 결합하면 FP 그룹의 미전환 원인을 더 명확히 파악할 수 있다.
- 실시간 점수 계산을 위한 파이프라인: 체험 2일차 시점에 실시간으로 입실/체류 로그를 집계하고 모델 점수를 계산하는 배치 파이프라인을 구성하면 운영에 바로 활용 가능하다.

5.3 분석 확장 제안

- XGBoost + SHAP: 비선형 관계(max_consecutive_days의 역U자 패턴 등)를 포착하려면 트리 기반 모델이 유리하다. SHAP를 활용하면 개별 예측에 대한 **feature** 기여도를 시각적으로 설명할 수 있어 영업팀과의 커뮤니케이션에도 효과적이다.
- 코호트 분석: 엔데믹 이후 결제율이 **7%p** 하락한 것이 단순 시기 효과인지, 신청자 풀의 특성 변화(방문 패턴, 업종 등)인지 코호트 분석으로 추가 검증할 필요가 있다.
- 지점별 모델 분리: 지점 규모와 위치에 따라 고객 특성이 다를 수 있다. 대형 지점(**150평 이상**)과 소형 지점(**50평**)을 분리하여 모델을 각각 구축하면 지점별 전략 수립이 가능하다.