



"결제 고객을 사전에 예측할 수 있을까?"

- 무료체험 기간 동안의 방문 행동 데이터를 기반으로 결제 전환 고객과 미전환 고객의 행동 차이를 분석함
- 체류시간, 방문 빈도, 방문 시점 등 주요 행동 변수를 활용해 결제 전환 예측 모델을 구축함
- 고객별 결제 가능성을 예측하여 마케팅 효율화 및 운영 의사결정 지원 가능성을 확인함

프로젝트 배경

공유오피스 운영사는 3일 무료체험 프로그램을 통해 체험 고객의 유료 멤버십 전환율 향상이 핵심 비즈니스 과제이다. 본 프로젝트는 무료체험 기간 동안의 이용 행동 데이터를 분석하여 결제전환에 영향을 미치는 주요 요인을 도출하고, XGBoost 기반 예측 모델을 통해 전환 가능성을 검증하고자 하였다.

데이터 소개



데이터 기간
2021.05 - 2023.12



분석 대상
9,624명



변수
6개


데이터 전처리

구 분	주요 컬럼	전처리 이슈	처리 방법	원본행수	정제 후 행수
등록 여부	user_id, date	동일 (user_uuid + trial_date) 중복 28건+ 동일 user_uuid 재신청 35건	마지막 신청 기준 1인 1체험신청으로 통합	9,659	9,624
로그	user_id, checkin, date	완전 중복 행 359건	마지막 건 유지	63,708	63,349
방문 여부	user_id, date, stay_time, first_enter, last_leave	입퇴실 시각 동시 결측 555건 / 중복 48건	결측 행 제거, 중복 최종 건 유지	11,477	10,874
결제 여부	user_id, payment	완전 중복 행 35건	마지막 건 유지	9,659	9,624
지점	site_id, area	UTC 기준 시각	KST(+9h) 변환 후 사용	9	9

데이터 주요 특징



방문일수가 많을수록
결제 전환율이 높음
(33% → 46%)



코로나 기간 결제율이
엔데믹 이후보다 높음
(7%p)



체류시간이 길수록
결제율이 낮음
(역 U자)



첫 방문이 늦을수록
결제율이 높음
(32 → 44%)



하루 입실횟수가 많을수록
결제율이 낮음

머신러닝 실험 흐름도

1. Baseline



기본 모델 성능 비교 및
Baseline 확보



기본 6개 변수
3개 모델 비교
(class_weight 미적용)

2. class_weight 추가



기본 모델 성능 비교 및
Baseline 확보



Recall 대폭 향상,
XGBoost가 가장 균형적
(F1=0.51) → 기준모델 선정

3. Feature Engineering



FE(42개) 적용 및
Threshold(0.4) 조정
영향 확인



Threshold 조정이
Recall과 F1개선에
더 큰 영향, FE효과 제한적

4. 최적 Threshold 탐색



Threshold=0.36에서
F1-score 최대(0.57),
Recall=0.84 달성



0.30~0.70 범위를
탐색하여 F1-score 최대화

5. 하이퍼파라미터 튜닝



Recall 0.94 달성하여
결제 가능 고객을 가장
효과적으로 탐지



XGBoost 하이퍼파라미터
튜닝으로 성능 최적화